

Report del Lavoro Svolto sul Dataset "Student Performance"

Obiettivo del Progetto

Il progetto ha come obiettivo il training di due modelli predittivi (classificazione tramite albero decisionale e rete multistrato) in grado di predire la classe di **GPA** (Grade Point Average) di uno studente a partire da un dataset che riporta alcune informazioni demografiche, familiari e sulle attività svolte dagli studenti. Un secondo obiettivo è quello di confrontare i due modelli dal punto di vista del carico computazionale e delle performance di predizione.

Descrizione del dataset

Il dataset contiene alcune informazioni su studenti delle scuole superiori, che descrivono i loro dati demografici, le abitudini di studio, il coinvolgimento dei genitori, le attività extracurricolari e il rendimento scolastico. La variabile target, GPA_interval, classifica i voti degli studenti in categorie distinte.

Descrizione delle features

Features	Tipo	Descrizione
Student ID	Int	Identificatore dello studente
Age	Int	Età degli studenti (15 - 18)
Sex	Int (categorico)	0: Maschio 1: Femmina
Ethnicity	Int (categorico)	Etnia: 0: Caucasian 1: African American 2: Asian 3: Other
Parent Education	Int (categorico)	Livello di educazione dei genitori: 0: None 1: High School 2: Some College 3: Bachelor's 4: Higher
StudyTimeWeekly	Float	Tempo di studio settimanale in ore (0 - 20).
Absences	Int (categorico)	Numero di assenze durante l'anno scolastico (0 - 30)
Tutoring	Int (categorico)	Stato del tutoraggio 0: no 1: si

Features	Tipo	Descrizione
Parental Support	Int (categorico)	Livello di supporto dei genitori 0: Nessuno 1: Basso 2: Moderato 3: Alto 4: Molto alt
Extracurricular	Int (categorico)	Partecipazione ad attività extracurricolari 0: no 1: si
Sports	Int (categorico)	Partecipazione ad attività sportive 0: no 1: si
Music	Int (categorico)	Partecipazione ad attività musicali 0: no 1: si
Volunteering	Int (categorico)	Partecipazione ad attività di volontariato 0: no 1: si
GPA	float	Media dei voti su una scala da 0 a 4

Definizione del target

A partire dal GPA, abbiamo definito il target diviso in classi come segue:

- Se il GPA è compreso tra 0 e 1, il target è 0
- Se il GPA è compreso tra 1 e 2, il target è 1
- Se il GPA è compreso tra 2 e 3, il target è 2
- Se il GPA è compreso tra 3 e 4, il target è 3

Eliminiamo poi la colonna del GPA, poiché direttamente correlata con il target

Analisi dei dati

Analisi preliminari

Dopo un primo sguardo alla composizione del dataset abbiamo che:


- Il dataset è composto 2392 istanze.
- Il dataset è composto da sole features numeriche
- Non ci sono valori mancanti.
- Non ci sono righe duplicate.

Target

Da una prima analisi sul dataset notiamo che la distribuzione del target è simile ad una distribuzione normale, quindi abbastanza sbilanciato.

Dovremo quindi tenere conto di questo durante la valutazione dei modelli, in quanto l'accuracy potrebbe non essere una metrica significativa in questo caso.


Useremo quindi l'F1-score come metrica di valutazione, in quanto siamo interessati sia alla precisione che al recall.



Features

Diamo uno sguardo alle features per capire come sono distribuite:

- Vediamo che la distribuzione dell'età e del sesso è bilanciata.
- L'etnia caucasica è la più presente, molto più rappresentata rispetto alle altre etnie.
- Il supporto parentale e l'istruzione parentale sono distribuiti in modo simile a una distribuzione normale.
- Gli studenti che svolgono attività extracurricolari sono di meno rispetto a quelli che non le svolgono.
- Notiamo inoltre che il tempo di studio e il numero di assenze, che a priori potrebbero essere le feature più significative per la predizione, sono distribuiti in modo abbastanza bilanciato.




Analisi della correlazione

Analizziamo la correlazione tra le features per capire se ci sono feature che sono correlate tra loro.

Vediamo che l'unica correlazione significativa con il target è quella con il numero di assenze. La correlazione è negativa, questo perché il target più alto corrisponde al voto maggiore, quindi ha senso che al crescere delle assenze il voto si abbassi.


Notiamo inoltre che non ci sono correlazioni significative tra le features, questo indica che non c'è multicollinearità, quindi ogni feature porta informazioni uniche.



Outliers

Verifichiamo ora la presenza di outliers nelle feature.

Ci concentriamo sulle features non categoriche, e vediamo che non ci sono outliers.



Pre-elaborazione dei dati

Encoding delle variabili categoriche

Effettuiamo l'encoding della variabile `Ethnicity` utilizzando la tecnica dell'encoding one-hot.

Inoltre droppiamo la categoria `Other` in quanto deducibile dalle altre colonne, e quindi introduce multicollinearità.

Manteniamo invece la feature `ParentalEducation` come variabile categorica espressa in termini di numeri, in quanto l'ordine crescente dei numeri rispecchia l'ordine dei titoli di studio.

Lo stesso vale per la feature `ParentalSupport`.

Le altre feature binarie sono già numeriche, quindi non necessitano di encoding.

Divisione del dataset

Dividiamo il dataset in training set e test set, utilizzando una proporzione di 30% per il training set e 30% per il test set.

Dividiamo inoltre il training set in training set e validation set, utilizzando una proporzione di 80% per il training set e 20% per il validation set.


Scelta dei modelli

Come modelli abbiamo scelto l'albero di decisione, un modello più leggero e che fornisce una migliore interpretabilità del processo di predizione, e la rete neurale, un modello più complesso e meno interpretabile, ma che si rivela più potente e flessibile nell'output.

Albero Decisionale

Parametro di complessità

Per ottimizzare il modello abbiamo innanzitutto cercato il valore migliore del parametro di complessità testando una serie di valori e scegliendo quello che ha prodotto le migliori prestazioni in termini di F1-score sul set di validazione.



Tuning degli iperparametri

Dopo aver individuato il valore più adatto, abbiamo perfezionato ulteriormente il modello esplorando diverse combinazioni di iperparametri utilizzando la tecnica di Grid Search con cross-validation, sempre utilizzando come metrica l'F1-score, per individuare i migliori.

```
Migliori iperparametri: {  
  'class_weight': None,  
  'criterion': 'entropy',  
  'max_depth': 15,  
  'min_samples_leaf': 2,  
  'min_samples_split': 10,  
  'splitter': 'random'}
```

Risultato del tuning

Infine, testiamo il modello con i migliori iperparametri sia sull'insieme di dati di validazione che su quello di test per verificare la sua capacità di classificare correttamente, e comparare i risultati per individuare un eventuale overfitting.

```

Classification Report - Validation Set:
              precision    recall  f1-score
macro avg      0.811      0.699      0.731
weighted avg    0.772      0.752      0.748

```

```



Classification Report - Test Set:
              precision    recall  f1-score
macro avg      0.751      0.713      0.728
weighted avg    0.739      0.734      0.734

```

Possiamo notare che non ci sia overfitting quindi addestriamo il modello con l'intero training set e valutiamo le performance sul test set.

Risultato finale

Dalla confusion-matrix possiamo notare che anche quando il modello sbaglia, sbaglia di massimo una classe. Gli errori sono quindi localizzati tra classi contigue, suggerendo che il modello ha una buona capacità di distinguere le categorie, anche se può esserci qualche sovrapposizione tra classi vicine.



L'analisi della curva ROC ottenuta evidenzia un buon comportamento del modello nella classificazione delle classi di GPA. L'area sotto la curva (AUC) risulta elevata, indicando un'ottima capacità discriminante tra le classi. La distanza dalla diagonale indica che il modello supera significativamente una classificazione casuale, mentre il bilanciamento tra TPR e FPR suggerisce un'adeguata

capacità di generalizzazione, ovvero riesce a distinguere correttamente tra classi senza essere troppo permissivo o troppo restrittivo. Questi risultati confermano la bontà del modello.

Rete multistrato

Abbiamo implementato poi un modello di rete multistrato per la classificazione, utilizzando tecniche di ottimizzazione e validazione incrociata per migliorare le prestazioni.

Tuning degli iperparametri

Per individuare il modello migliore, abbiamo provato diverse combinazioni di iperparametri utilizzando la tecnica di Grid Search con cross-validation, sempre utilizzando come metrica l'F1-score, per individuare i migliori.

```
F1-macro: 0.814 Parametri: {'hidden_layer_sizes': (50,), 'optimizer': 'adam' }
F1-macro: 0.822 Parametri: {'hidden_layer_sizes': (50,), 'optimizer': 'sgd' }
F1-macro: 0.806 Parametri: {'hidden_layer_sizes': (100,), 'optimizer': 'adam' }
F1-macro: 0.807 Parametri: {'hidden_layer_sizes': (100,), 'optimizer': 'sgd' }
F1-macro: 0.818 Parametri: {'hidden_layer_sizes': (50, 50), 'optimizer': 'adam' }
F1-macro: 0.819 Parametri: {'hidden_layer_sizes': (50, 50), 'optimizer': 'sgd' }
F1-macro: 0.807 Parametri: {'hidden_layer_sizes': (25, 50, 25), 'optimizer': 'adam' }
F1-macro: 0.821 Parametri: {'hidden_layer_sizes': (25, 50, 25), 'optimizer': 'sgd' }
```

Possiamo notare che tutte le configurazioni della rete sono circa equivalenti, in quanto gli F1-score (macro-average) si distanziano di poco, rimanendo nel margine d'errore.

```
Migliori iperparametri: {'hidden_layer_sizes': (50,), 'optimizer': 'sgd' }
```

Il modello scelto è costruito con uno strato nascosto denso e utilizza SGD come ottimizzatore, ReLU come funzione di attivazione nei layer nascosti e Softmax nell'output per la classificazione multiclasse. La funzione di loss scelta è `categorical_crossentropy`, adatta alla gestione di target categorici.

Per ridurre il rischio di overfitting, vengono applicate le seguenti tecniche:

- **Early Stopping:** Se il modello non migliora per 10 epoche consecutive, l'allenamento viene fermato e il modello viene ripristinato al miglior stato.
- **Dropout:** Con un tasso di 0.2, disattiva casualmente il 20% dei neuroni nei layer densi durante l'allenamento per migliorare la generalizzazione.
- **Batch Normalization:** Applicata ai layer nascosti, normalizza gli input per stabilizzare l'addestramento e accelerare la convergenza.

Risultato del modello tunato

Classification Report - Validation Set:


	precision	recall	f1-score
macro avg	0.863	0.822	0.839
weighted avg	0.848	0.845	0.844

Classification Report - Test Set:


	precision	recall	f1-score
macro avg	0.867	0.854	0.859
weighted avg	0.860	0.859	0.859

Possiamo notare che anche questa volta non risulta overfitting quindi addestriamo il modello con l'intero training set e valutiamo le performance sul test set.

Risultato del modello finale



Anche questa volta gli errori sono localizzati tra classi contigue, suggerendo che il modello ha una buona capacità di distinguere le categorie, anche se può esserci qualche sovrapposizione tra classi vicine.



L'analisi della curva ROC ottenuta evidenzia un buon comportamento del modello nella classificazione delle classi di GPA. L'area sotto la curva (AUC) risulta elevata, indicando un'ottima capacità discriminante tra le classi. La distanza dalla diagonale indica che il modello supera significativamente una classificazione casuale, mentre il bilanciamento tra TPR e FPR suggerisce un'adeguata capacità di generalizzazione, ovvero riesce a distinguere correttamente tra classi senza essere troppo permissivo o troppo restrittivo. Questi risultati confermano la bontà del modello.

Confronto modelli

Classification Report - Test Set:					Classification Report - Test Set:				
	precision	recall	f1-score			precision	recall	f1-score	
0	0.823	0.847	0.835		0	0.804	0.956	0.873	
1	0.757	0.773	0.765		1	0.854	0.761	0.804	
2	0.733	0.770	0.751		2	0.818	0.831	0.824	
3	0.772	0.610	0.682		3	0.833	0.800	0.816	
accuracy			0.763		micro avg	0.827	0.827	0.827	
macro avg	0.771	0.750	0.758		macro avg	0.827	0.837	0.830	
weighted avg	0.764	0.763	0.762		weighted avg	0.829	0.827	0.826	
					samples avg	0.827	0.827	0.827	

Considerazioni finali

Nel nostro contesto i risultati mostrano che la rete multistrato classifica in modo piú corretto (sarebbe inoltre possibile ottenere in output direttamente il punteggio GPA, in forma di numero continuo), di contro richiede piú tempo per il training. L'albero decisionale invece presenta performance di predizione peggiori, ma é piú veloce e inoltre fornisce un processo decisionale interpretabile.